

LAPORAN TEKNIS PROYEK ECO-WISE

Analisis dan Implementasi Klasifikasi Sampah Berbasis Deep Learning

1. Analisis Permasalahan dan Solusi (*Problem Discovery*)

Proyek Eco-Wise ini bertujuan untuk mengatasi permasalahan krusial dalam pengelolaan sampah yang efisien, khususnya yang berkaitan dengan pemisahan berbagai jenis sampah langsung dari sumbernya. Pengelolaan sampah yang tidak tepat, terutama akibat kesalahan pemilihan, sering kali menghambat proses daur ulang karena terjadinya kontaminasi silang antar-material.

Sebagai jawaban atas tantangan tersebut, proyek Eco-Wise hadir dengan solusi teknologi cerdas berupa pengembangan model klasifikasi gambar berbasis *Deep Learning* menggunakan arsitektur MobileNetV2 yang secara otomatis mampu mengidentifikasi kategori sampah. Model ini dirancang untuk diintegrasikan ke dalam sistem tempat sampah pintar (*smart bin*) atau aplikasi pemilihan mandiri berbasis *web*.

2. Pengumpulan Data (*Data Gathering*)

Dataset utama yang mendasari pengembangan ini diperoleh dari data Kaggle : Trashcan yang mencakup data sebanyak 17.620 gambar limbah sampah yang terbagi ke dalam 4 klasifikasi, yaitu :

- Anorganik: Mencakup material seperti kertas, botol plastik, plastik jenis PET, kardus, rag (kain), kantong belanja, wadah makanan kemasan, dan logam/kaleng.
- B3 (Bahan Berbahaya dan Beracun) : Mencakup limbah domestik, berbahaya seperti baterai bekas, wadah kosmetik

kaca, kemasan obat/kapsul, kaleng aerosol, dan botol detergen kimia.

- Organik : Mencakup sampah biologis mudah terurai seperti sisa makanan (*food waste*), kulit telur, tisu bekas, dedaunan, dan sisa sayuran.
- Non-Waste : Objek acak di sekitar lingkungan (*random object*).

Tahap ini melibatkan persiapan awal yang dibutuhkan untuk seluruh rangkaian proses, termasuk mengimpor berbagai *library* yang dibutuhkan, pengaturan *variabel* global (misalnya, ukuran gambar dan seed), serta koneksi ke Google Drive untuk mengakses dataset. Dataset diekstraksi dari format ZIP untuk diolah lebih lanjut.

Pada tahapan loading data, dilakukan pengintegrasian antara Google Colab dengan Google Drive untuk mengekstrak file arsip *ecowise_dataset.zip* ke dalam direktori kerja folder *dataset-trashcan*. Struktur folder diatur secara hierarkis berdasarkan label kategori utama dan subfolder material.

2.1 Import Library

Pada bagian Import Library merupakan fondasi awal yang krusial untuk keseluruhan proyek Eco-Wise. Pemilihan dan pengimporan library ini secara kolektif mencerminkan cakupan teknis proyek, mulai dari pengelolaan data dasar hingga implementasi model *Deep Learning* yang kompleks.

1) Operasi Dasar dan Pengelolaan File

- *os, pathlib, shutil, random, zipfile, glob, json* : Library ini sangat penting untuk berinteraksi dengan sistem operasi,

mengelola jalur file dan direktori, mengekstrak dataset dari file ZIP, menghasilkan nilai acak (misalnya untuk inisialisasi atau augmentasi), dan membaca atau /menulis metadata dalam format JSON. Ini memastikan bahwa dataset dapat diakses, diatur, dan dipersiapkan dengan baik.

2) Pengelolaan Data dan Komputasi Numerik

- `numpy` dan `pandas`: Merupakan tulang punggung untuk manipulasi dan analisis data numerik dan tabular. `numpy` esensial untuk operasi array multidimensi (sangat penting untuk data gambar), sementara `pandas` digunakan untuk mengelola data terstruktur seperti `DataFrame`, memfasilitasi EDA dan preprocessing.
- `tqdm.notebook`: Memungkinkan visualisasi progres yang interaktif, yang berguna untuk memantau proses yang memakan waktu seperti pemrosesan gambar.

3) Library Khusus Google Colab

- `google.colab.drive`: Ini krusial karena proyek ini kemungkinan besar menyimpan dataset di Google Drive, sehingga library ini memungkinkan koneksi antara notebook Colab dan Drive untuk akses data.

4) Visualisasi Data

- `matplotlib.pyplot` dan `seaborn`: Vital untuk Exploratory Data Analysis (EDA). Keduanya digunakan untuk membuat berbagai jenis plot dan grafik (seperti distribusi kelas, rasio aspek, kecerahan) yang membantu dalam memahami karakteristik dataset dan mengidentifikasi pola atau anomali.

5) Pengolahan Gambar dan *Machine Learning*

- PIL.Image: Digunakan untuk membuka, memanipulasi, dan menyimpan gambar, yang merupakan langkah dasar dalam setiap proyek berbasis visi komputer.
- collections.Counter: Membantu dalam analisis statistik seperti menghitung frekuensi mode warna gambar.
- tensorflow dan tensorflow.keras: Ini adalah framework utama untuk membangun, melatih, dan mengevaluasi model Deep Learning. Pemilihan MobileNetV2 sebagai model aplikasi menunjukkan pendekatan transfer learning untuk efisiensi dan performa.
- tensorflow.keras.layers, models, callbacks, optimizers, regularizers.l2: Komponen-komponen ini memungkinkan definisi arsitektur model, pengaturan proses pelatihan (seperti early stopping), pemilihan algoritma optimasi, dan pencegahan overfitting.
- tensorflow.keras.preprocessing.image: Utilitas untuk preprocessing gambar yang sesuai dengan model Keras.

6) Scikit-learn

- sklearn.model_selection.train_test_split: Penting untuk membagi dataset menjadi set pelatihan, validasi, dan pengujian secara sistematis.
- sklearn.utils.class_weight: Sangat krusial untuk menangani class imbalance (ketidakseimbangan kelas) yang sering terjadi pada dataset dunia nyata, memastikan model tidak bias terhadap kelas mayoritas.

- `sklearn.metrics.confusion_matrix`, `classification_report`: Digunakan untuk evaluasi kinerja model secara mendalam, memberikan metrik seperti precision, recall, dan F1-score.

7) MLflow

- `mlflow` dan `mlflow.tensorflow`: Mengindikasikan bahwa proyek ini akan menggunakan MLflow untuk melacak eksperimen, mengelola versi model, dan mereproduksi hasil, yang sangat penting dalam pengembangan ML yang terstruktur dan kolaboratif.

8) Penanganan *Warning*

- `warnings`: Digunakan untuk menonaktifkan peringatan yang tidak relevan, menjaga output notebook tetap bersih dan fokus pada informasi penting.

2.2 Konfigurasi Dasar

Bagian 'Konfigurasi Dasar' menentukan parameter-parameter inti yang akan memengaruhi cara data diproses dan model dilatih. Pemilihan nilai untuk setiap variabel ini didasarkan pada praktik terbaik dalam Deep Learning dan kebutuhan spesifik proyek klasifikasi gambar Eco-Wise.

1) `IMG_SIZE = (224, 224)`

Ukuran gambar input standar ini dipilih karena merupakan dimensi yang umum digunakan oleh banyak arsitektur Convolutional Neural Network (CNN) pra-terlatih (seperti MobileNetV2 yang digunakan dalam proyek ini). Ini memastikan konsistensi input ke model dan memungkinkan penggunaan transfer learning yang efisien, di mana fitur-fitur yang dipelajari dari dataset besar seperti ImageNet dapat diterapkan pada dataset ini. Ini juga menyederhanakan preprocessing karena semua gambar akan di-resize ke ukuran ini.

2) `BATCH_SIZE = 32`

`BATCH_SIZE` (ukuran batch) menentukan jumlah sampel gambar yang akan diproses pada satu waktu sebelum parameter model diperbarui. Ukuran 32 adalah nilai yang umum dan seimbang. Batch yang lebih besar dapat mempercepat pelatihan dan memberikan estimasi gradien yang lebih stabil, tetapi membutuhkan lebih banyak memori GPU. Batch yang lebih kecil dapat membantu generalisasi dan mencegah overfitting tetapi mungkin memperlambat pelatihan. Pemilihan 32 menunjukkan upaya untuk menyeimbangkan efisiensi komputasi dengan stabilitas pelatihan.

3) `SEED = 42`

Penetapan `SEED` (benih acak) dengan nilai 42 (atau nilai konstan lainnya) sangat krusial untuk reproduktivitas. Dalam eksperimen Deep Learning, ada banyak proses acak (misalnya inisialisasi bobot model, pembagian dataset, augmentasi data). Dengan menetapkan seed, setiap kali kode dijalankan dengan seed yang sama, hasil acak yang dihasilkan akan identik, sehingga memungkinkan peneliti atau pengembang lain untuk mendapatkan hasil yang sama dan memverifikasi eksperimen.

4) `AUTOTUNE = tf.data.AUTOTUNE`

`tf.data.AUTOTUNE` adalah fitur TensorFlow yang secara otomatis menyesuaikan jumlah thread paralel untuk operasi preprocessing dan pemuatan data. Ini bertujuan untuk mengoptimalkan kinerja pipeline data, memastikan bahwa GPU tidak menunggu data dari CPU, sehingga memaksimalkan pemanfaatan sumber daya dan mempercepat waktu pelatihan secara keseluruhan. Ini menunjukkan perhatian terhadap efisiensi end-to-end dalam alur kerja pelatihan.

Konfigurasi dasar ini menunjukkan pendekatan yang terencana dan berorientasi pada kinerja dalam proyek Eco-Wise. Dengan menentukan `IMG_SIZE` yang kompatibel untuk transfer learning, `BATCH_SIZE` yang seimbang untuk efisiensi dan stabilitas,

SEED untuk reproduktivitas, dan AUTOTUNE untuk optimasi pipeline data, proyek ini membangun fondasi yang kuat untuk pelatihan model Deep Learning yang efektif dan efisien. Ini adalah langkah awal yang esensial untuk memastikan bahwa data dipersiapkan dengan baik dan model dapat belajar secara optimal dari dataset gambar yang ada.

2.3 Data Loading

Bagian 'Data Loading' menetapkan bagaimana dataset diakses dari Google Drive dan diubah menjadi format yang siap untuk Exploratory Data Analysis (EDA). Langkah-langkah ini sangat penting untuk memastikan data tersedia, terstruktur, dan dapat diolah.

1) Definisi Path Dataset

- `drive_path`, `project_folder`, `dataset_name_zip`, `extracted_dataset_folder_name`: Variabel-variabel ini dengan jelas mendefinisikan lokasi file ZIP dataset (`ecowise_dataset.zip`) di dalam Google Drive dan nama folder tempat data akan diekstrak (`dataset-trashcan`). Ini menunjukkan praktik yang baik dalam mengorganisir data proyek di cloud.
- `dataset_base_path`, `zip_file_path`, `dataset_dir`, `base_path_split`: Path-path ini dikonstruksi secara programatis menggunakan `os.path.join`, yang membuatnya lebih fleksibel dan cross-platform dibandingkan dengan menulis path secara hardcoded. Ini juga mencakup path untuk data yang nantinya akan di-split (latih, validasi, uji).

2) Ekstraksi Dataset Kondisional

- Kode menggunakan `if not os.path.exists(dataset_dir)` untuk memeriksa apakah dataset sudah diekstrak. Jika belum, ia akan mengekstrak file ZIP ke lokasi yang ditentukan. Ini adalah pendekatan yang cerdas karena :

- Efisiensi: Mencegah ekstraksi berulang yang memakan waktu dan sumber daya setiap kali notebook dijalankan kembali jika folder sudah ada.
- Robustness: Memastikan dataset selalu tersedia dalam bentuk yang tidak terkompresi sebelum langkah-langkah selanjutnya.
- Penggunaan `get_ipython().system('unzip -q ...')` menunjukkan interaksi langsung dengan shell sistem, yang umum dalam lingkungan Colab untuk operasi file.

3) Pengumpulan Path Gambar dan Label Awal

- Proses ini secara iteratif memindai struktur folder yang sudah diekstrak (`dataset_dir/kelas/subfolder/gambar.jpg`). Ini adalah metode standar untuk mendapatkan label dari dataset gambar yang terstruktur berdasarkan direktori.
- `all_file_paths_eda` menyimpan jalur lengkap setiap gambar.
- `all_labels_initial_eda` menyimpan label detail (misalnya 'Anorganik (PET)').
- `all_labels_main_eda` menyimpan label kategori utama (misalnya 'Anorganik'). Pemisahan ini sangat berguna untuk analisis di berbagai tingkat granularitas.
- Ekstraksi Metadata Awal: Saat mengumpulkan path, kode juga mencoba membuka setiap gambar untuk mendapatkan `image_modes_eda` (mode warna seperti RGB) dan `image_sizes_eda` (dimensi lebar dan tinggi). Informasi ini sangat berharga untuk EDA terkait kualitas dan karakteristik gambar, seperti rasio aspek dan distribusi ukuran. Meskipun ini dapat memunculkan peringatan 'DecompressionBombWarning' untuk gambar yang sangat besar, ini adalah cara efisien untuk mendapatkan metadata awal.

- Penanganan Error: Adanya blok try-except saat membuka gambar (with Image.open(img_path)) menunjukkan upaya untuk membuat proses lebih robust, sehingga tidak berhenti total jika ada satu atau beberapa gambar yang rusak/tidak dapat dibaca.

4) Pembuatan DataFrame untuk EDA (df_eda)

- Semua informasi yang terkumpul (path, label detail, label utama) diorganisir ke dalam sebuah Pandas DataFrame. Ini menciptakan basis data terstruktur yang solid untuk semua analisis data eksplorasi dan preprocessing selanjutnya. DataFrame ini menjadi "sumber kebenaran" untuk metadata dataset gambar.
- Tahap 'Data Loading' ini adalah fondasi krusial bagi keseluruhan proyek Eco-Wise. Ini berhasil membangun pipeline yang efisien dan robust untuk:
 - Mengakses dan Mengelola Dataset: Dengan cerdas menangani ekstraksi file ZIP dan struktur direktori dataset dari Google Drive.
 - Mengekstrak Metadata Penting: Mengumpulkan informasi jalur file, label (utama dan detail), serta karakteristik gambar dasar (mode warna, ukuran) secara otomatis.
 - Menciptakan Basis Data Terorganisir: Menyatukan semua informasi ini ke dalam sebuah Pandas DataFrame (df_eda) yang menjadi landasan untuk analisis, pembersihan, dan persiapan data selanjutnya.

Dengan data yang sudah dimuat dan terstruktur dengan baik pada tahap ini, proyek siap untuk melanjutkan ke fase eksplorasi dan pembersihan data dengan percaya diri.

2.4 Mengumpulkan Path Gambar dan Label Awal untuk EDA

Bagian ini secara sistematis memindai folder dataset yang sudah diekstrak untuk mengidentifikasi setiap file gambar, mengumpulkan jalur lengkapnya, dan mengekstrak label kategori dari struktur direktori. Proses ini bukan hanya tentang daftar file, tetapi juga tentang pengorganisasian metadata penting yang akan menjadi dasar untuk analisis dan preprocessing selanjutnya.

1) Ekstraksi Label Otomatis dari Struktur Direktori

- Kode ini mengandalkan konvensi penamaan folder (dataset_dir/kelas/subfolder/gambar.jpg) untuk secara otomatis menentukan label utama (Anorganik, B3, Organik, Non-Waste) dan label yang lebih detail atau sub-kategori (PET, random_objects, battery, kardus). Ini adalah metode yang sangat umum dan efisien dalam dataset gambar yang terorganisir.
- all_labels_initial_eda (contoh: "Anorganik (PET)") dan all_labels_main_eda (contoh: "Anorganik") dibuat, memungkinkan analisis pada dua tingkat granularitas yang berbeda. Ini sangat berharga untuk memahami distribusi data dari perspektif yang luas hingga spesifik.

2) Pengumpulan Metadata Gambar Esensial (Mode dan Ukuran)

- Dengan menggunakan PIL.Image.open(img_path), kode tidak hanya memverifikasi bahwa file adalah gambar yang dapat dibaca, tetapi juga mengekstrak mode warna (img.mode, e.g., 'RGB', 'L') dan ukuran (img.size, e.g., (width, height)) setiap gambar.
- Mengumpulkan metadata ini di awal proses (ke dalam image_modes_eda dan image_sizes_eda) sangat penting untuk EDA. Informasi ini memungkinkan analisis lebih lanjut tentang:
 - Kualitas Gambar

- Rasio Aspek
- Variasi Ukuran
- Meskipun ada potensi `DecompressionBombWarning` untuk gambar yang sangat besar, ini adalah tradeoff yang dapat diterima untuk mendapatkan gambaran menyeluruh tentang karakteristik gambar di seluruh dataset.

3) Pentingnya `df_eda` sebagai Sumber Kebenaran

- Semua informasi yang terkumpul (`path`, `labels_initial`, `labels_main`) kemudian diorganisir ke dalam sebuah Pandas DataFrame (`df_eda`). Ini mengubah kumpulan data gambar yang tersebar menjadi format tabular yang terstruktur dan mudah dimanipulasi.
- `df_eda` menjadi "sumber kebenaran" untuk semua metadata dataset, yang akan digunakan secara konsisten dalam seluruh tahapan EDA, pembersihan data, dan persiapan untuk model.

4) Penanganan Error dan Validasi Awal

- Adanya blok `try-except` saat membaca informasi gambar menunjukkan upaya untuk membuat proses lebih robust. Jika ada gambar yang rusak atau tidak dapat diakses, proses tidak akan berhenti total, melainkan melompat ke gambar berikutnya.
- Pengecekan `if not all_file_paths_eda: raise ValueError(...)` memastikan bahwa proses tidak berlanjut jika tidak ada gambar yang ditemukan, memberikan umpan balik yang jelas kepada pengguna.

Langkah 'Mengumpulkan Path Gambar dan Label Awal untuk EDA' ini adalah fondasi analitis proyek. Ini berhasil menciptakan sebuah inventaris komprehensif dari setiap gambar dalam dataset, tidak hanya mencatat lokasinya tetapi juga mengekstrak label kategori dan

metadata penting seperti mode warna dan dimensi. Dengan mengorganisir informasi ini ke dalam `df_eda`, proyek ini memastikan bahwa seluruh proses EDA dan preprocessing selanjutnya akan didasarkan pada data yang terstruktur, teridentifikasi, dan siap untuk dianalisis. Ini adalah langkah kunci dalam memastikan kualitas dan konsistensi data yang akan digunakan untuk melatih model Deep Learning.

3. Penilaian Data (*Data Assessing*)

Proses pemindaian awal (*Assesing Data*) dilakukan dengan memanfaatkan pustaka Pandas untuk membentuk struktur `df_eda` guna merekam jalur file (*path*), label granular awal (*labels_initial*), dan label makro target (*labels_main*).

1) Kelengkapan dan Struktur Data

- Dataset terstruktur dengan baik, berisi 17.620 entri gambar dengan 3 kolom (`path`, `labels_initial`, `labels_main`). Semua kolom bertipe objek dan lengkap, artinya tidak ada nilai yang hilang (`df_eda.isna().sum()` menunjukkan 0 untuk semua). Ini memastikan bahwa setiap entri memiliki informasi lengkap, yang penting untuk analisis dan pelatihan model yang andal.

2) Integritas Data (Tidak ada Duplikat atau Gambar Rusak)

- Dataset menunjukkan integritas yang tinggi. Tidak ada baris duplikat (`df_eda.duplicated().sum()` menunjukkan 0), menjamin bahwa setiap entri data adalah unik dan mencegah bias selama pelatihan model. Selain itu, tidak ada gambar yang rusak yang ditemukan, yang merupakan indikator positif yang kuat untuk kualitas dan keandalan data gambar untuk pembelajaran mendalam.

3) Distribusi Kelas

- Kategori Utama (labels_main) : Data dikategorikan menjadi 4 kelas utama (Anorganik, B3, Organik, Non-Waste). 'Anorganik' adalah kategori yang paling dominan dengan 6.471 gambar. Ini menunjukkan pemahaman awal tentang distribusi kelas secara keseluruhan.
- Sub-kategori (labels_initial) : Terdapat 20 sub-kategori unik, menyediakan klasifikasi yang lebih terperinci. 'Non-Waste (random_objects)' adalah sub-kategori yang paling sering muncul dengan 1.649 gambar. Ini menunjukkan dataset yang bervariasi dan terperinci tetapi juga mengisyaratkan potensi masalah ketidakseimbangan kelas pada tingkat kategori utama dan sub-kategori, yang perlu diperhatikan pada tahap pra-pemrosesan selanjutnya.

Penilaian awal menunjukkan dataset berkualitas tinggi yang bersih, lengkap, dan bebas dari duplikat serta gambar yang rusak. Fondasi yang kuat ini sangat baik untuk melanjutkan analisis data lebih lanjut dan pengembangan model. Area utama yang diidentifikasi untuk perhatian pada langkah-langkah berikutnya adalah potensi ketidakseimbangan kelas di seluruh kategori utama dan terperinci, yang harus diatasi selama pra-pemrosesan untuk memastikan model klasifikasi yang kuat dan berkinerja adil.

4. Pembersihan Data (*Data Cleaning*)

1) Penanganan Missing Values

- Dataset ini menunjukkan kualitas yang sangat tinggi sejak awal. Pemeriksaan terhadap missing values di kolom path, labels_initial, maupun labels_main menunjukkan bahwa tidak ada satupun nilai yang hilang. Hal ini berarti setiap entri data sudah lengkap dan utuh, sehingga tidak diperlukan tindakan khusus untuk mengisi atau menghapus data yang tidak ada.

2) Penanganan Duplikasi Data

- Sama seperti missing values, dataset juga terbukti sangat bersih dari duplikasi. Pemeriksaan duplikasi mengkonfirmasi bahwa tidak ada baris yang terduplikasi secara identik dalam DataFrame. Ini sangat penting karena menjamin bahwa setiap entri data adalah unik dan merepresentasikan informasi yang berbeda, mencegah bias dalam analisis statistik dan pelatihan model.

3) Standarisasi Label

- Langkah clening yang paling signifikan adalah standarisasi label pada kolom labels_main. Semua label telah dikonversi ke format 'Title Case' (misalnya, Anorganik, Organik, B3, dan Non-Waste). Standarisasi dilakukan untuk :
 - Konsistensi : Memastikan semua label memiliki format yang seragam, menghindari kesalahan interpretasi.
 - Akurasi model : Mempermudah model untuk mengidentifikasi dan mengelompokkan kategori dengan benar, karena tidak ada variasi penulisan yang dapat membingungkan model.
 - Distribusi Kelas Setelah Standarisasi : Distribusi kelas tetap sama setelah standarisasi karena tidak ada perubahan pada isi data, hanya formatnya.

Proses data cleaning ini menegaskan bahwa dataset Eco-Wise memiliki kualitas yang sangat baik dan bersih dari awal. Tidak adanya missing values dan duplikasi data adalah fondasi yang kokoh untuk analisis lebih lanjut dan pengembangan model. Satu-satunya intervensi yang diperlukan adalah standarisasi label, yang berhasil menciptakan konsistensi dalam representasi kelas. Hasilnya, kita memiliki dataset yang rapi, terorganisir, dan siap sepenuhnya untuk tahap analisis

eksplorasi data (EDA) yang lebih mendalam serta persiapan model deep learning tanpa perlu khawatir tentang masalah kualitas data dasar.

5. *Exploratory Data Analysis* (EDA) & *Explanatory Data Analysis* (XDA)

Tahap ini bertujuan untuk membedah karakteristik visual dan statistik intrinsik dari dataset Eco-Wise untuk memvalidasi kelayakan data sebelum tahap training model.

5.1 Explanatory Data Analysis (EDA)

1) Variasi Gambar yang Baik

Visualisasi sampel gambar menunjukkan bahwa dataset memiliki variasi yang cukup kaya dari segi objek, latar belakang, pencahayaan, dan sudut pengambilan. Ini adalah karakteristik positif karena model akan dilatih pada data yang beragam, sehingga diharapkan mampu melakukan generalisasi dengan baik pada kondisi dunia nyata. Namun, kompleksitas ini juga berarti model perlu dirancang agar cukup *robust* untuk menangani variasi tersebut.

2) Ketidakseimbangan Kelas Utama

Analisis distribusi gambar per kelas utama (Anorganik, B3, Organik, Non-Waste) menunjukkan adanya ketidakseimbangan yang signifikan. Kategori Anorganik (6.471 gambar) dan Organik (6.000 gambar) adalah yang paling dominan, sementara B3 (3.500 gambar) dan terutama Non-Waste (1.649 gambar) adalah kelas minoritas. Ketidakseimbangan ini perlu diatasi pada tahap *preprocessing* agar model tidak bias dan memiliki performa yang adil di semua kelas.

3) Distribusi Material yang Detail dan Potensi Imbalance Lebih Lanjut

Pada tingkat material yang lebih spesifik (*labels_initial*), terdapat banyak jenis material yang memiliki jumlah gambar seragam (sekitar 1.000 atau 500 gambar). Namun, terdapat anomali seperti Non-Waste (*Random_objects*) yang tinggi (1.649 gambar) dan Anorganik (HDPEM) yang relatif rendah (451 gambar). Hal ini menegaskan

kembali perlunya strategi penanganan ketidakseimbangan, terutama jika model akan memprediksi pada tingkat granularitas ini.

4) Variasi Rasio Aspek Gambar

Mayoritas gambar memiliki rasio aspek mendekati 1.0 (persegi), namun terdapat rentang yang luas dari 0.28 hingga 6.21. Ini berarti dataset mengandung gambar potret dan lanskap yang ekstrem. *Preprocessing* gambar yang melibatkan *resizing* atau *cropping* harus mempertimbangkan variasi ini untuk menghindari distorsi informasi penting atau hilangnya konteks.

5) Distribusi Kecerahan yang Seimbang dengan Rentang Luas

Tingkat kecerahan gambar sebagian besar terpusat pada nilai sedang (rata-rata sekitar 172), menunjukkan pencahayaan yang umumnya baik. Namun, adanya gambar yang sangat gelap (min 19.78) hingga sangat terang (maks 249.34) adalah hal positif. Model akan dihadapkan pada berbagai kondisi pencahayaan, yang akan meningkatkan *robustness*-nya. *Preprocessing* seperti normalisasi piksel menjadi sangat penting untuk memastikan konsistensi input ke model.

6) Ukuran Gambar yang Beragam dan Perlunya Standarisasi

Setiap kategori utama memiliki banyak ukuran gambar unik (ratusan hingga ribuan). Ini menunjukkan bahwa gambar-gambar asli datang dengan resolusi dan dimensi yang bervariasi. Oleh karena itu, standarisasi ukuran gambar (misalnya, ke `IMG_SIZE = (224, 224)` seperti yang telah ditentukan) selama *preprocessing* adalah keharusan untuk memastikan input yang konsisten ke jaringan saraf tiruan.

5.2 Explanatory Data Analysis (XDA)

1) Dominasi dan Ketidakseimbangan Kategori Utama

Analisis proporsi kategori utama secara jelas menunjukkan bahwa Anorganik (36.7%) dan Organik (34.0%) adalah kategori yang paling dominan dalam dataset. Sebaliknya, B3 (19.9%) dan Non-Waste (9.3%) memiliki representasi yang jauh lebih kecil. Ini adalah temuan krusial yang mengindikasikan adanya ketidakseimbangan kelas yang signifikan. Model yang tidak ditangani dengan strategi khusus kemungkinan akan menunjukkan kinerja yang lebih baik pada kelas mayoritas (Anorganik, Organik) dan kinerja yang suboptimal pada kelas minoritas (B3, Non-Waste).

2) Variasi Distribusi Material Spesifik

Pada tingkat material yang lebih granular (`labels_initial`), dataset menunjukkan dua pola distribusi :

- **Distribusi Seragam** : Banyak material seperti PET, rag, bungkus makanan, kaleng, kaca (Anorganik), kardus, eggshells, kertas, daun, food waste, tissue (Organik), dan baterai (B3) memiliki jumlah gambar yang relatif seragam (sekitar 1.000 gambar). Beberapa material B3 lainnya (botol deterjen plastik, wadah kosmetik kaca, kapsul tablet, kaleng aerosol, botol obat) juga seragam dengan 500 gambar masing-masing. Keseragaman ini berpotensi mempermudah model untuk mempelajari fitur unik dari setiap material ini.
- **Material yang Outlier** : Terdapat material yang sangat dominan seperti Non-Waste (`random_objects`) dengan 1.649 gambar, dan sebaliknya, material yang sangat minim seperti Anorganik (HDPEM) dengan hanya 451 gambar. Perbedaan drastis ini menunjukkan bahwa meskipun ada keseragaman, masih ada kebutuhan untuk penanganan khusus bagi

material yang sangat terwakili atau sangat kurang terwakili untuk mencegah bias dan memastikan model belajar secara komprehensif.

3) Implikasi untuk Pengembangan Model :

Berdasarkan wawasan dari XDA ini, terdapat beberapa implikasi penting untuk strategi pengembangan model:

- Fokus pada Penanganan Ketidakseimbangan: Penggunaan teknik seperti *oversampling* untuk kelas minoritas, *undersampling* untuk kelas mayoritas, atau penerapan *class weights* dalam fungsi *loss* model akan sangat penting. Ini bertujuan untuk memastikan model tidak bias terhadap kelas yang dominan dan dapat belajar secara efektif dari kelas-kelas minoritas.
- Peluang Klasifikasi Multigranular: Dataset ini menawarkan potensi untuk melatih model klasifikasi pada dua tingkat granularitas: kategori utama dan material spesifik. Namun, perlu diwaspadai bahwa performa pada tingkat material spesifik mungkin bervariasi tergantung pada jumlah sampel yang tersedia untuk setiap jenis material.
- Evaluasi yang Cermat: Metrik evaluasi model harus dipilih dengan hati-hati untuk mengatasi ketidakseimbangan kelas. Disarankan untuk menggunakan *precision*, *recall*, dan *F1-score* per kelas, selain akurasi keseluruhan, untuk mendapatkan gambaran performa model yang lebih jujur dan komprehensif.

XDA telah berhasil mengidentifikasi kekuatan dataset dalam variasi material serta tantangan utama dalam ketidakseimbangan kelas. Informasi ini menyediakan dasar yang kuat untuk merancang

strategi *data preprocessing* dan arsitektur model yang akan memaksimalkan kemampuan klasifikasi sampah Eco-Wise. Penanganan yang efektif terhadap ketidakseimbangan kelas akan menjadi kunci untuk membangun model yang *robust* dan akurat, mampu mengidentifikasi semua jenis sampah dengan baik.

6. Prapemrosesan Data untuk Model (*Preprocessing*)

1) Pembuatan Manifest Dataset

Langkah ini sangat krusial karena mengorganisir seluruh metadata gambar (path, kategori, sub-kategori, dimensi, rasio aspek) ke dalam satu DataFrame (*df_manifest*). Ini memudahkan manajemen data terpusat, memungkinkan ekstraksi fitur dasar (seperti rasio aspek), dan memastikan hanya gambar valid yang diproses. Manifest ini menjadi fondasi yang kuat untuk pembagian data selanjutnya.

2) Pembagian Data (Train, Validation, Test) dengan Stratified Split

Dataset dibagi menjadi set pelatihan (80%), validasi (10%), dan pengujian (10%) menggunakan *stratified split* berdasarkan *sub_kategori*. Pendekatan ini vital untuk :

- **Menjaga Representasi Kelas:** Memastikan setiap kategori dan sub-kategori terwakili secara proporsional di setiap set, mengatasi masalah ketidakseimbangan kelas yang terdeteksi di EDA.
- **Evaluasi Model Akurat:** Menjamin bahwa metrik evaluasi model pada set validasi dan pengujian merefleksikan performa model secara adil di semua kelas, tidak bias oleh distribusi data.
- **Distribusi Data yang Solid:** Menghasilkan 12.686 gambar untuk pelatihan, 3.172 untuk validasi, dan 1.762 untuk

pengujian, yang merupakan proporsi yang seimbang untuk pembelajaran dan evaluasi model.

3) Penyalinan Gambar ke Folder Split

Proses menyalin gambar ke struktur folder `split_name/label_folder/image.jpg` memungkinkan `tf.keras.utils.image_dataset_from_directory` untuk secara otomatis mengidentifikasi kelas dari nama folder dan memuat data secara efisien ke dalam format `tf.data.Dataset`. Ini sangat penting untuk konsistensi input ke model TensorFlow/Keras.

4) Penghitungan Class Weight

Berdasarkan analisis ketidakseimbangan kelas, *class weights* dihitung dan akan digunakan selama pelatihan model. Ini berfungsi untuk :

- Mengurangi Bias: Memberikan bobot lebih tinggi pada sampel dari kelas minoritas (misalnya, Non-Waste) dan bobot lebih rendah pada kelas mayoritas (Anorganik, Organik).
- Meningkatkan Sensitivitas: Membantu model untuk lebih fokus dan belajar dari kelas-kelas yang kurang terwakili, sehingga meningkatkan *recall* dan *precision* pada kelas tersebut dan menghasilkan performa yang lebih seimbang di seluruh kategori.

5) Data Augmentasi dan Preprocessing Pipeline untuk MobileNetV2

Penerapan pipeline yang mencakup `RandomFlip`, `RandomRotation`, `RandomZoom`, `RandomContrast`, diikuti oleh `tf.keras.applications.mobilenet_v2.preprocess_input` adalah kunci untuk:

- **Robustness Model:** Augmentasi data secara artifisial memperluas dataset pelatihan, membuat model lebih tangguh terhadap variasi dalam orientasi, ukuran, dan pencahayaan gambar.
- **Optimalisasi MobileNetV2:** Fungsi `preprocess_input` menormalisasi piksel gambar ke rentang `[-1, 1]`, sesuai dengan ekspektasi MobileNetV2 yang telah dilatih sebelumnya di ImageNet, memaksimalkan efektivitas *transfer learning*.
- **Efisiensi:** Penggunaan `tf.data.AUTOTUNE` memastikan pipeline berjalan efisien, mencegah *bottleneck* I/O selama pelatihan.

Tahap *preprocessing* ini secara metodis telah mengubah data mentah menjadi format yang optimal, konsisten, dan siap untuk dilatih oleh model *deep learning*. Dengan penanganan ketidakseimbangan kelas melalui *stratified split* dan *class weighting*, peningkatan keragaman data melalui augmentasi, serta normalisasi yang sesuai dengan arsitektur MobileNetV2, dataset kini memiliki fondasi yang kuat untuk menghasilkan model klasifikasi sampah Eco-Wise yang berkinerja tinggi, akurat, dan *robust* terhadap variasi data di dunia nyata. Semua langkah ini secara kolektif berkontribusi pada mitigasi tantangan yang diidentifikasi selama EDA dan XDA.

7. Kamus Data (*Data Dictionary*)

Data Dictionary merangkum informasi esensial mengenai dataset, dari gambaran umum hingga detail karakteristik gambar dan pembagian data. Ini berfungsi sebagai referensi komprehensif untuk memahami struktur dan konten dataset yang digunakan dalam proyek.

1) Kualitas Dataset dan Ukuran yang Signifikan

Dataset Eco-Wise memiliki 17.620 gambar dan 0 gambar rusak (corrupt). Ini menunjukkan dataset yang besar dan berkualitas tinggi, menjadi fondasi yang sangat baik untuk melatih model *deep learning* yang *robust*.

2) Struktur Klasifikasi Berlapis

Dataset ini terorganisir dengan baik ke dalam 4 kategori utama (Anorganik, B3, Organik, Non-Waste) dan 20 sub-kategori material yang lebih spesifik. Struktur ini memungkinkan pengembangan model yang dapat mengklasifikasikan sampah pada berbagai tingkat granularitas, dari kategori umum hingga jenis material yang detail.

3) Ketidakseimbangan Kelas yang Terkonfirmasi

Data dictionary dengan jelas mengonfirmasi ketidakseimbangan kelas yang signifikan pada kategori utama, dengan Anorganik (6.471 gambar) dan Organik (6.000 gambar) sebagai mayoritas, sedangkan B3 (3.500 gambar) dan Non-Waste (1.649 gambar) adalah minoritas. Ketidakseimbangan ini juga terlihat pada sub-kategori, misalnya Non-Waste (Random_Objects) yang tinggi (1.649) dan Anorganik (HDPEM) yang rendah (451). Hal ini menekankan pentingnya strategi penanganan ketidakseimbangan (misalnya *class weighting* atau *oversampling*) selama pelatihan model.

4) Variasi Karakteristik Gambar yang Kaya

- Mode Warna: Mayoritas gambar menggunakan mode RGB (17.544), yang merupakan format standar untuk *deep learning* gambar, mempermudah integrasi ke model.
- Ukuran dan Rasio Aspek: Dataset menampilkan banyak ukuran gambar unik secara awal, serta rentang rasio aspek yang luas (0.28 hingga 6.21) dengan median 1.0. Variasi ini adalah aset karena membuat model lebih *robust* terhadap

berbagai orientasi dan bentuk gambar di dunia nyata. Namun, juga menggarisbawahi kebutuhan untuk *resizing* standar dan *data augmentation* (seperti *random zoom* atau *flip*) untuk konsistensi input model.

- Kecerahan: Distribusi kecerahan gambar terdistribusi dengan baik (rata-rata sekitar 172) dengan rentang yang luas (min 19.78 hingga max 249.34). Ini menunjukkan model akan dihadapkan pada berbagai kondisi pencahayaan, yang baik untuk *robustness*, tetapi juga membutuhkan normalisasi piksel (misalnya ke $[-1, 1]$ seperti yang dilakukan MobileNetV2).

5) Pembagian Data yang Strategis

Data telah dibagi dengan proporsi yang solid untuk set pelatihan (12.686 gambar), validasi (3.172 gambar), dan pengujian (1.762 gambar). Pembagian ini esensial untuk melatih, mengevaluasi, dan menguji generalisasi model secara efektif.

Data Dictionary berfungsi sebagai ringkasan eksekutif yang memvalidasi bahwa dataset Eco-Wise adalah aset berharga untuk proyek ini. Dataset ini besar, berkualitas tinggi, dan terstruktur dengan baik, namun memiliki tantangan utama berupa ketidakseimbangan kelas. Detail tentang karakteristik gambar (variasi ukuran, rasio aspek, dan kecerahan) juga menyoroti perlunya *preprocessing* dan *data augmentation* yang cermat. Semua informasi ini akan menjadi peta jalan yang tidak ternilai dalam merancang dan mengimplementasikan model klasifikasi *deep learning* yang tidak hanya akurat tetapi juga adil dan *robust* terhadap data sampah di dunia nyata.

8. Kesimpulan dan Rekomendasi

Bagian terakhir ini merangkum temuan kunci dari proyek Eco-Wise, mulai dari analisis masalah, pemrosesan data, hingga hasil evaluasi model. Kesimpulan akan mencakup:

- **Pencapaian Proyek:** Seberapa baik model yang dikembangkan berhasil mengklasifikasikan sampah dan apakah tujuan awal proyek tercapai.
- **Pembelajaran dan Tantangan:** Insight yang diperoleh selama proses pengembangan, serta tantangan yang dihadapi (misalnya, ketidakseimbangan data, optimasi model).
- **Rekomendasi untuk Pengembangan Selanjutnya:** Usulan untuk peningkatan model di masa depan, seperti penggunaan arsitektur yang lebih canggih, pengumpulan data tambahan, atau teknik fine-tuning yang lebih agresif. Juga akan dibahas potensi integrasi model ke dalam sistem nyata dan dampak yang diharapkan terhadap pengelolaan sampah.